Yasin Ünal
503020250009
HW4

Colab not defterinin hücre hücre açıklamaları sırasıyla yapılarak sonuçlar paylaşılacaktır.

1. Kütüphanelerin import edilmesi :

```
import torch
import torch.nn as nn
import torch.nn.functional as F
from torchvision import datasets, transforms
from torch.utils.data import DataLoader
from torch.optim import Adam
from sklearn.metrics import confusion_matrix, accuracy_score, f1_score,
roc_auc_score
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
import os
```

2. Mish aktivasyon fonksiyonunun tanımlanması

```
class Mish(nn.Module):
    def forward(self, x):
        return x * torch.tanh(F.softplus(x))
```

Mish aktivasyon fonksiyonunun kullanım amacı daha yumuşak bir geçiş sağlamak ve modelin öğrenmesinde stabilite sağlamaktır. Bu fonksiyonun gerçeklenmesinde aşağıdaki kaynaktan yararlanılmıştır.

* https://paperswithcode.com/method/mish

Mish fonksiyonunun matematiksel gösterimi aşağıdaki gibidir :

$$\text{Mish}(x) = x \cdot \tanh(\ln(1 + e^x))$$

3. Verilen CNN Mimarisinin oluşturulması

```
class CNNModel(nn.Module):
    def __init__(self, num_classes):
        super(CNNModel, self).__init__()
        self.conv1 = nn.Conv2d(3, 32, 3, padding=1)     # ilk katman
        self.conv2 = nn.Conv2d(32, 64, 3, padding=1)    # ikinci katmsn
        self.dropout1 = nn.Dropout(0.3)                 # dropout katmanı (%30)
        self.pool = nn.MaxPool2d(2, 2)                  # Pooling katmanı (2x2)

        self.conv3 = nn.Conv2d(64, 128, 3, padding=1)   # üçüncü katman
        self.conv4 = nn.Conv2d(128, 256, 3, padding=1)  # dördüncü katman
        self.dropout2 = nn.Dropout(0.4)                 # dropout katmanı  (%40)

        self.fc1 = nn.Linear(256 * 56 * 56, 256)    # tam boyutlu bağlantı katmanı
        self.fc2 = nn.Linear(256, num_classes)      # sonuç sınıf sayısı
        self.act = Mish()                           # aktivasyon fonksiyonu

    def forward(self, x):
        x = self.act(self.conv1(x))                 # ilk conv katmanı ve çıktısının aktivasyona verilmesi
        x = self.pool(self.act(self.conv2(x)))      # ikinci conv katmanı, çıktının aktivasyon ve poolinge verilmesi
        x = self.dropout1(x)                        # dropout katmanı (%30)
        x = self.act(self.conv3(x))                 # üçüncü conv katmanı ve çıktısının aktivasyona verilmesi
        x = self.pool(self.act(self.conv4(x)))      # dördüncü conv katmanı, çıktının aktivasyon ve poolinge verilmesi
        x = self.dropout2(x)                        # dropout katmanı (%40)
        x = x.view(x.size(0), -1)                   # Flattening işlemi {-1 boyutunu otomatik ayarlar}
        x = self.fc1(x)                             # full connected katmanı
        x = self.fc2(x)                             # son full connected katmanı
        return x
```

Resimde verilen mimarinin aynısını yansitan CNN mimarisi için bir Class oluşturuldu ve init metodunda her bir adım gerçeklendi. forward( ) metodunda ise ileri yayılım işlemi tanımlandı.

4. Verilerin alınacağı konumun seçilmesi.

```
# data_dir = "CaltechTinySplit"
from google.colab import drive
drive.mount('/content/drive')

# Example: Accessing a file in your Google Drive's "Colab Notebooks"
folder
data_dir = "/content/drive/MyDrive/Makale-Döküman-Makale Çalışmaları/YL
Dersler/Derin Öğrenme Uygulamaları/HW/HW4-CNN/CaltechTinySplit"
```

Local'de çalışırken data_dir ile Colab üzerinde çalışırken farklı olduğu için çalışılan ortama göre data_dir ayarlanır.

5. Pytorch ile verilerin train/validate/test olarak ayrıştırılması

```
transform = transforms.Compose([
    transforms.Resize((224, 224)),
    transforms.ToTensor()
])

train_ds = datasets.ImageFolder(os.path.join(data_dir, 'train'),
transform=transform)
val_ds = datasets.ImageFolder(os.path.join(data_dir, 'val'),
transform=transform)
test_ds = datasets.ImageFolder(os.path.join(data_dir, 'test'),
transform=transform)

train_loader = DataLoader(train_ds, batch_size=16, shuffle=True)
val_loader = DataLoader(val_ds, batch_size=16)
test_loader = DataLoader(test_ds, batch_size=16)
```

İlk olarak transform ile tüm resimler aynı boyuta getirilir. Mimari'de resim input'u 224*224 boyutunda olduğu için bu şekilde formatlanır. Ardından torchvision üzerinden resimler dataset haline getirilir ve DataLoader ile kullanıma uygun veri formatına getirilir. Shuffle True ile verisetinin karıştırılması sağlanır.

6. Train metodunun oluşturulması

```
def train_model(model, criterion, optimizer, scheduler, num_epochs=50):
    model.train()
    for ep in range(num_epochs):
        total, correct, loss_sum = 0, 0, 0
        for x, y in train_loader:
            x, y = x.to(device), y.to(device)
            optimizer.zero_grad()
            out = model(x)
            loss = criterion(out, y)
            loss.backward()
            optimizer.step()
            _, pred = torch.max(out, 1)
            total += y.size(0)
            correct += (pred == y).sum().item()
            loss_sum += loss.item()
        scheduler.step()
        print(f"Epoch {ep+1}/{num_epochs} - Loss: {loss_sum:.4f} - Acc:
{100*correct/total:.2f}%")
```

Tanımlanan CNN modeli alınarak eğitim için başlatılır. Her epoch'da gradyanlar sıfırlanır ve backward ile geriyeyayılım yapılır. Ardından step ile ağırlıklar güncellenir. Her iterasyonda konsole bilgiler yazdırılır.

7. Test / Model değerlendirme fonksiyonu

```
def evaluate(model, loader):
    model.eval()
    y_true, y_pred, y_prob = [], [], []
    with torch.no_grad():
        for x, y in loader:
            x, y = x.to(device), y.to(device)
            out = model(x)
            prob = F.softmax(out, dim=1)
            _, pred = torch.max(prob, 1)
            y_true.extend(y.cpu().numpy())
            y_pred.extend(pred.cpu().numpy())
            y_prob.extend(prob.cpu().numpy())
    return y_true, y_pred, np.array(y_prob)
```

Modelin test edilmesi için kullanılacak olan metoddur. eval( ) ile dropout gibi işlemlerin devre dışı bırakılması yapıldıktan sonra ileri yayılım ile tahmin yapılması sağlanır. Modelin tahmin ettiği sonuç mimaride istendiği gibi softmax aktivasyonundan geçirilir ve olasılık haline getirilir. Elde edilen sonuçlar döndürülür.

8. Modelin initialize edilmesi ve train işlemlerinin başlatılması

```
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
model = CNNModel(len(train_ds.classes)).to(device)
criterion = nn.CrossEntropyLoss()
optimizer = Adam(model.parameters(), lr=1e-3)
scheduler = torch.optim.lr_scheduler.MultiStepLR(optimizer,
milestones=[20, 40], gamma=0.3)

train_model(model, criterion, optimizer, scheduler)
torch.save(model.state_dict(), 'cnn_mish_model.pt')
```

GPU içeren ortamlar için device bilgisinin alınması sonrasında CNNModel initialize edilir, ödevde istenen parametreler ile train işlemleri başlatılır. Elde edilen model sonucu .pt uzantılı olarak kaydedilir.

9. Modelin yüklenmesi ve test edilmesi

```
model.load_state_dict(torch.load('cnn_mish_model.pt'))
y_true, y_pred, y_prob = evaluate(model, test_loader)

acc = accuracy_score(y_true, y_pred)
f1 = f1_score(y_true, y_pred, average='weighted')
try:
    auc = roc_auc_score(y_true, y_prob, multi_class='ovr')
except:
    auc = 'AUC hesaplanamadı'

print(f"Accuracy: {acc:.4f}, F1: {f1:.4f}, AUC: {auc}")

cm = confusion_matrix(y_true, y_pred)
plt.figure(figsize=(10, 8))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
            xticklabels=train_ds.classes, yticklabels=train_ds.classes)
plt.xlabel('Predicted')
plt.ylabel('True')
plt.title('Confusion Matrix')
plt.show()
```

Son aşama olarak önceki adımda kaydedilen model dosyadan okunur ve evaluate metodunda test veriseti ile test edilir. Elde edilen metrikler (auc, f1, confisuon matrix) çıktı olarak konsola yazdırılır.

10. Elde edilen sonuçlar

```
Epoch 1/50 - Loss: 403.5346 - Acc: 65.01%
Epoch 2/50 - Loss: 53.3376 - Acc: 83.80%
Epoch 3/50 - Loss: 26.2889 - Acc: 89.67%
Epoch 4/50 - Loss: 18.3249 - Acc: 92.79%
Epoch 5/50 - Loss: 6.4313 - Acc: 98.22%
Epoch 6/50 - Loss: 3.2802 - Acc: 98.96%
Epoch 7/50 - Loss: 1.2963 - Acc: 99.70%
Epoch 8/50 - Loss: 6.0624 - Acc: 98.14%
Epoch 9/50 - Loss: 27.8444 - Acc: 92.20%
Epoch 10/50 - Loss: 7.4570 - Acc: 97.62%
Epoch 11/50 - Loss: 1.2554 - Acc: 99.70%
Epoch 12/50 - Loss: 0.1298 - Acc: 100.00%
Epoch 13/50 - Loss: 0.0527 - Acc: 100.00%
Epoch 14/50 - Loss: 0.0219 - Acc: 100.00%
Epoch 15/50 - Loss: 0.0201 - Acc: 100.00%
Epoch 16/50 - Loss: 0.0153 - Acc: 100.00%
Epoch 17/50 - Loss: 0.0129 - Acc: 100.00%
Epoch 18/50 - Loss: 0.0108 - Acc: 100.00%
Epoch 19/50 - Loss: 0.0095 - Acc: 100.00%
Epoch 20/50 - Loss: 0.0085 - Acc: 100.00%
Epoch 21/50 - Loss: 0.0083 - Acc: 100.00%
Epoch 22/50 - Loss: 0.0076 - Acc: 100.00%
Epoch 23/50 - Loss: 0.0073 - Acc: 100.00%
Epoch 24/50 - Loss: 0.0069 - Acc: 100.00%
Epoch 25/50 - Loss: 0.0068 - Acc: 100.00%
Epoch 26/50 - Loss: 0.0067 - Acc: 100.00%
Epoch 27/50 - Loss: 0.0065 - Acc: 100.00%
Epoch 28/50 - Loss: 0.0062 - Acc: 100.00%
Epoch 29/50 - Loss: 0.0060 - Acc: 100.00%
```

```
Epoch 30/50 - Loss: 0.0057 - Acc: 100.00%
Epoch 31/50 - Loss: 0.0056 - Acc: 100.00%
Epoch 32/50 - Loss: 0.0055 - Acc: 100.00%
Epoch 33/50 - Loss: 0.0054 - Acc: 100.00%
Epoch 34/50 - Loss: 0.0050 - Acc: 100.00%
Epoch 35/50 - Loss: 0.0049 - Acc: 100.00%
Epoch 36/50 - Loss: 0.0047 - Acc: 100.00%
Epoch 37/50 - Loss: 0.0045 - Acc: 100.00%
Epoch 38/50 - Loss: 0.0044 - Acc: 100.00%
Epoch 39/50 - Loss: 0.0040 - Acc: 100.00%
Epoch 40/50 - Loss: 0.0038 - Acc: 100.00%
Epoch 41/50 - Loss: 0.0040 - Acc: 100.00%
Epoch 42/50 - Loss: 0.0038 - Acc: 100.00%
Epoch 43/50 - Loss: 0.0040 - Acc: 100.00%
Epoch 44/50 - Loss: 0.0036 - Acc: 100.00%
Epoch 45/50 - Loss: 0.0037 - Acc: 100.00%
Epoch 46/50 - Loss: 0.0038 - Acc: 100.00%
Epoch 47/50 - Loss: 0.0035 - Acc: 100.00%
Epoch 48/50 - Loss: 0.0035 - Acc: 100.00%
Epoch 49/50 - Loss: 0.0033 - Acc: 100.00%
Epoch 50/50 - Loss: 0.0032 - Acc: 100.00%
```

Accuracy: 0.8793, F1: 0.8713, AUC: 0.980772327731886

Confisuon Matrix :

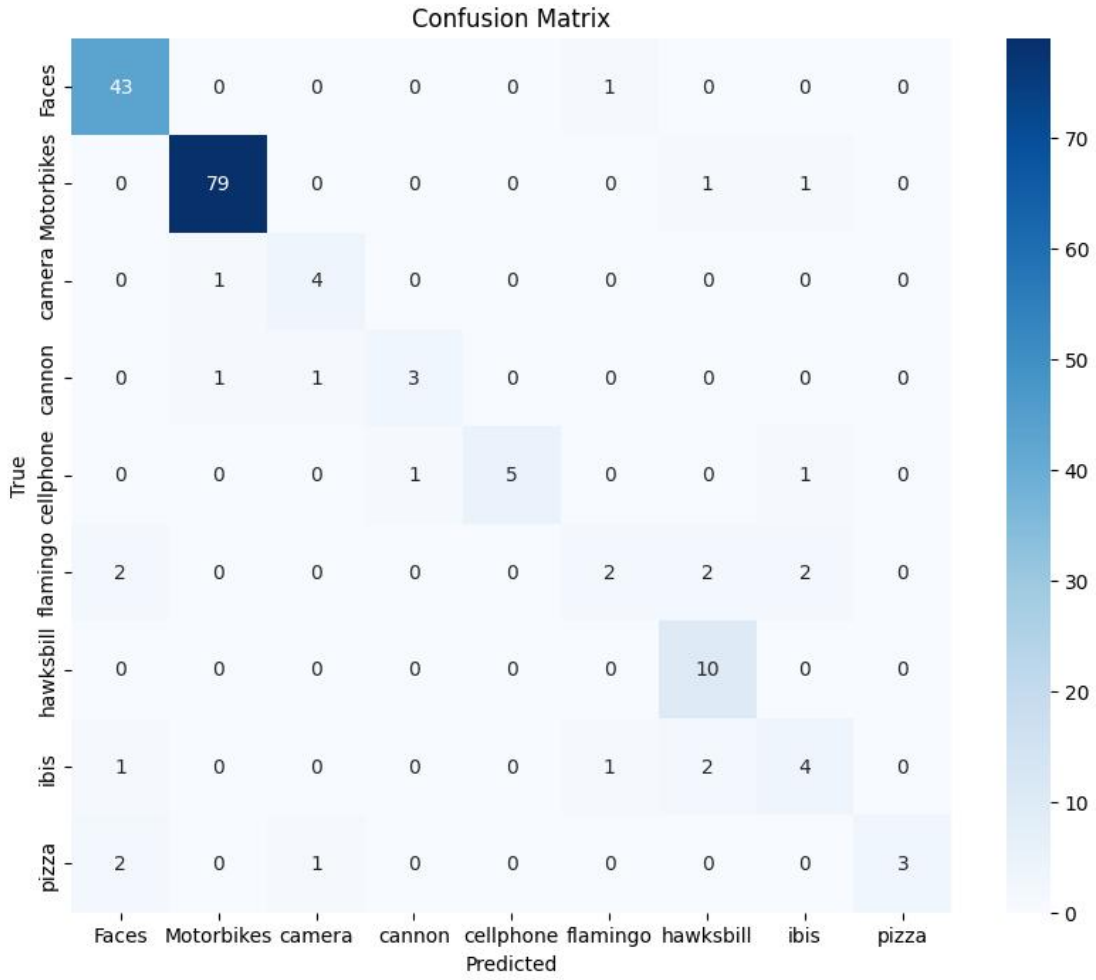

Modelin train üzerindeki çıktıları incelendiğinde 12.epoch sonrası accuracy %100 olduğu görülmekte. Bu da modelin train verilerinde ezberlediğini (overfit) göstermektedir.

Modelin test verisi üzerinde gösterdiği genel performans aşağıdaki metriklerle ölçülmüştür:

Accuracy (Doğruluk): 0.8793

F1-Score (Ağırlıklı Ortalama): 0.8713

AUC (ROC-AUC): 0.9808

Karışıklık matrisi incelendiğinde

- **Faces** ve **Motorbikes** sınıflarında model neredeyse mükemmele yakın performans göstermiştir. Sırasıyla 43 ve 79 örneği doğru sınıflandırmıştır.

- **Hawksbill** sınıfında tamamı doğru tahmin edilmiştir.

- Camera, **Cannon** ve **Cellphone** gibi bazı sınıflarda karışıklık gözlemlenmiştir.

Flamingo, **Ibis** ve **Pizza** gibi az örnekli sınıflarda sınırlı başarı sağlanmıştır. Bu sınıflar, genel model doğruluğunu düşüren ana etkenler olabilir.